UNIVERSITÉ LIBRE DES PAYS DES GRANDS LACS
FACULTÉ DE SCIENCES DE L'INGÉNIEUR
DÉPARTEMENT DE GÉNIE ET INFORMATIQUE

BP. 368 GOMA — www.ulpgl.net

TRAVAIL PRATIQUE DE IMAGE PROCESSING

Par KAVUGHO NYONDO MARIE
Option : Génie Informatique | Promotion : Master 2 | Année académique 2025-2026

1. Introduction

Une entreprise de production de jus souhaite transformer des oranges, des pommes, des tamarillos (*matunda damu*) et des bananes, mélangés après la récolte. Leur tri manuel mobilise plusieurs personnes, demande beaucoup d'efforts et prend du temps. Nous proposons un système intelligent de tri automatique, capable de reconnaître et de séparer les fruits par catégorie grâce à la vision par ordinateur et à l'apprentissage profond (Deep Learning).

Problématique : Comment concevoir un système intelligent capable de classifier automatiquement les différents types de fruits afin de réduire les efforts humains et de faciliter leur traitement industriel ?

2. Méthodologie

Démarche : collecte et préparation d'images de fruits, puis entraînement de deux modèles d'apprentissage profond, un CNN simple et ResNet-18, pour la reconnaissance automatique.

2.1. Outils et matériels utilisés

- **Deux smartphones** (Samsung et Google Pixel) : photos des fruits sous différents angles et conditions.
- **Google Colab** : exécution du code Python, préparation des images et entraînement des modèles.
- **LessMB** : outil gratuit de compression réduisant de 80 à 85 % la taille des photos (2 à 3 Mo), ce qui facilite stockage et transfert.
- **Python et bibliothèques de Deep Learning** : organisation du dataset, prétraitement, entraînement et prédictions.

2.2. Collecte et préparation des images

Quatre catégories ont été photographiées avec les deux smartphones (bananes, oranges, pommes, tamarillos) pour diversifier les images et limiter la dépendance à un seul appareil. Le dataset initial compte **320 images, soit 80 par catégorie**. Après compression (LessMB, −80 à −85 %, information visuelle suffisante conservée), les images ont été classées en dossiers par classe, préparées dans Google Colab et redimensionnées : **128 × 128 pixels** pour le CNN simple, **224 × 224 pixels** pour ResNet-18.

2.3. Répartition du dataset

Trois ensembles : **70 % (224 photos) pour l'entraînement**, **15 % (48 photos) pour la validation** et **15 % (48 photos) pour le test**. L'entraînement sert à apprendre les caractéristiques des fruits, la validation à suivre les performances pendant l'apprentissage, le test à évaluer le modèle sur des images mises de côté.

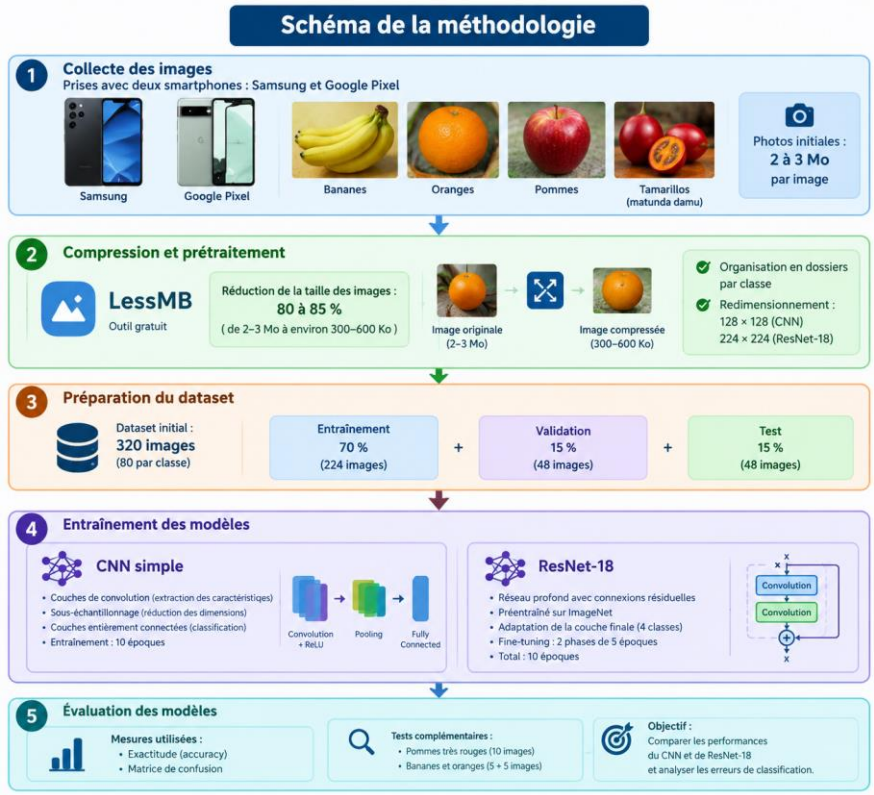
2.4. Entraînement des modèles

a) Réseau de neurones convolutifs (CNN). Réseau conçu pour traiter des images : des couches de convolution extraient les caractéristiques visuelles (contours, formes, textures), des couches de sous-échantillonnage réduisent les dimensions, puis les couches finales attribuent une catégorie. Le CNN simple a été entraîné pendant **10 époques** (une époque = un passage complet sur les données d'entraînement).

b) ResNet-18 et transfert d'apprentissage. Réseau convolutif plus profond, préentraîné sur ImageNet, dont les connexions résiduelles facilitent l'apprentissage et qui réutilise des caractéristiques déjà apprises. Sa couche de classification a été adaptée aux quatre fruits et entraînée seule, puis le modèle a été affiné par fine-tuning : **deux phases de cinq époques, soit 10 époques au total**.

2.5. Évaluation des modèles

Mesures : exactitude (*accuracy*, proportion d'images correctement classées) et matrice de confusion (bonnes prédictions et confusions entre catégories). Des tests complémentaires ont porté sur de nouvelles images : pommes très rouges, bananes et oranges photographiées séparément.



3. Résultats expérimentaux

3.1. Présentation du dataset

Le dataset comprend **320 images réparties en quatre classes** : bananes, oranges, pommes et tamarillos (*matunda damu*), avec 80 images par classe. Elles ont été collectées avec deux smartphones (Samsung, Google Pixel), puis compressées et préparées avant leur utilisation dans Google Colab. Elles constituent les données de base pour entraîner les modèles et évaluer leur capacité à reconnaître les différentes catégories de fruits.

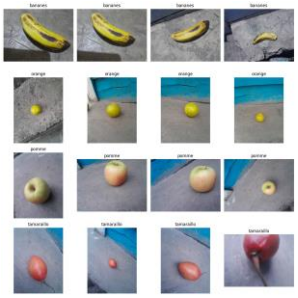


Figure 1 : Exemples d'images du dataset.

3.2. Entraînement du CNN simple

Premier modèle : CNN entraîné pendant 10 époques sur des images de 128 × 128 pixels. Exactitude d'entraînement **72,77 %**, de validation **64,58 %**, de test **64,58 %**. Le CNN reconnaît une partie des fruits mais distingue encore mal certaines catégories.

3.3. Matrice de confusion du CNN

Sur les 48 images de test, **31 sont correctement classées (64,58 %)**. Les tamarillos sont les mieux reconnus (11 sur 12) ; les oranges et les pommes posent davantage de difficultés (6 sur 12 chacune). Les principales erreurs sont des oranges et des pommes prédites comme bananes : le CNN simple ne distingue pas encore suffisamment certaines caractéristiques visuelles des fruits.

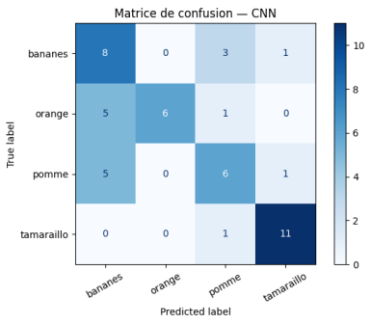


Figure 2 : Matrice de confusion du CNN simple.

3.4. Résultats de l'entraînement et de l'évaluation de ResNet-18

Entraînement en deux phases : cinq époques pour la couche de classification adaptée aux quatre fruits, puis cinq époques de fine-tuning, sur des images de 224 × 224 pixels.

3.4.1. Première phase d'entraînement

Époque	Perte entraînement	Précision entraînement	Perte validation	Précision validation
1	1,3052	38,84 %	0,8991	75,00 %
2	0,7529	83,04 %	0,6042	87,50 %
3	0,4917	91,96 %	0,4467	95,83 %
4	0,3563	95,54 %	0,3760	95,83 %
5	0,2810	95,98 %	0,3060	97,92 %

Interprétation : la précision d'entraînement passe de 38,84 % à 95,98 % et celle de validation atteint 97,92 % ; les pertes diminuent. Le modèle apprend progressivement à reconnaître les catégories de fruits.

3.4.2. Deuxième phase : fine-tuning de ResNet-18

Époque	Perte entraînement	Précision entraînement	Perte validation	Précision validation
1	0,4452	86,61 %	0,2936	95,83 %
2	0,3007	95,09 %	0,2612	93,75 %
3	0,1888	99,11 %	0,2237	95,83 %
4	0,1512	98,66 %	0,1964	95,83 %
5	0,1209	100,00 %	0,1696	95,83 %

Interprétation : la précision d'entraînement atteint 100 % (perte de 0,1209) et celle de validation reste entre 93,75 % et 95,83 %. L'écart entraînement/validation à la dernière époque est à surveiller, mais ne suffit pas à démontrer un surapprentissage important.

3.4.3. Matrice de confusion

Les lignes représentent les classes réelles, les colonnes les classes prédites.

Classe réelle / prédite	Bananes	Oranges	Pommes	Tamarillos
Bananes	12	0	0	0
Oranges	0	12	0	0
Pommes	0	1	11	0
Tamarillos	0	0	0	12

Interprétation : les 12 bananes, 12 oranges et 12 tamarillos sont correctement classés ; 11 pommes sur 12 sont reconnues, une étant confondue avec une orange. La matrice confirme **47 prédictions correctes sur 48, soit 97,92 %** d'exactitude.

3.4.4. Rapport de classification

Classe	Précision (Precision)	Rappel (Recall)	F1-score	Effectif
Bananes	1,00	1,00	1,00	12
Oranges	0,92	1,00	0,96	12
Pommes	1,00	0,92	0,96	12
Tamarillos	1,00	1,00	1,00	12
Moyenne macro	0,98	0,98	0,98	48
Moyenne pondérée	0,98	0,98	0,98	48

La précision mesure la proportion de prédictions d'une classe qui sont correctes ; le rappel, la proportion d'images réelles de cette classe correctement retrouvées ; le F1-score combine les deux. Les 12 oranges sont toutes reconnues (rappel 1,00), mais la pomme prédite comme orange ramène leur précision à 0,92 ; pour les pommes, la précision est de 1,00 et le rappel de 0,92.

4. Comparaison et interprétation des performances du CNN et de ResNet-18

Indicateur	CNN simple	ResNet-18
Époques d'entraînement	10	10, en deux phases
Précision d'entraînement finale	72,77 %	100,00 %
Précision de validation rapportée	64,58 %	95,83 % à la fin du fine-tuning
Précision de test	64,58 %	97,92 %

ResNet-18 obtient une exactitude de test supérieure : **97,92 % contre 64,58 %**, soit **+33,34 points de pourcentage**. Le transfert d'apprentissage semble donc particulièrement utile ici, le dataset ne comptant que 320 images. ResNet-18

réutilise les caractéristiques apprises sur ImageNet ; ses connexions résiduelles facilitent des représentations plus complexes ; l'adaptation de sa couche finale et le fine-tuning le spécialisent sur les quatre fruits.

> **Remarque sur la constitution du jeu de données :** il faut collecter, pour chaque classe, des fruits à différents niveaux de maturité (verts ou peu mûrs, moyennement mûrs, très mûrs). Dans notre jeu de données, les pommes étaient toutes moyennement mûres, ce qui pourrait expliquer l'échec du test avec une pomme très rouge : précision de seulement **10 %**, les neuf autres prédictions étant classées comme tamarillos. La diversité des images (couleur, degré de maturité) est essentielle à la capacité de généralisation du modèle.

En conclusion, ResNet-18 présente les meilleures performances sur le jeu de test initial, mais ces résultats ne garantissent pas une reconnaissance parfaite dans toutes les conditions, comme l'ont montré les pommes très rouges. Il serait utile d'enrichir le dataset et de varier les couleurs et la maturité (fruits mûrs et non mûrs, pommes rouges et vertes) pour améliorer la généralisation du système.

Conclusion générale

Nous avons conçu et expérimenté un système intelligent de classification des fruits fondé sur les réseaux de neurones convolutifs (CNN), afin de faciliter le tri automatique des bananes, oranges, pommes et tamarillos et de répondre au problème du tri manuel, coûteux en temps et en efforts humains. Deux approches ont été évaluées : un CNN entraîné à partir de zéro et ResNet-18 par apprentissage par transfert (*Transfer Learning*).

Sur les images de test, le CNN classique atteint **64,58 %** d'exactitude, contre **97,92 %** pour ResNet-18, plus efficace dans les conditions de notre expérimentation.

Comme limite et perspective ; Des confusions subsistent (une pomme prédite comme orange ; pommes très rouges prédites comme tamarillos), dues aux ressemblances visuelles et au manque de diversité de couleur et de maturité pour éviter les biais dans le résultats. Il faudrait enrichir le jeu de données avec des images plus diversifiées et tester le système en conditions réelles. À terme, la solution pourrait être intégrée à une machine équipée d'une caméra et d'un mécanisme de séparation automatique, pour un tri plus rapide, plus efficace et moins dépendant de l'intervention humaine.